

CardioIA

A Nova Era da Cardiologia Inteligente

FASE 1 — BATIMENTOS DE DADOS

Documento Resumo da Entrega

FIAP — Graduação em Inteligência Artificial

Metodologia Project Based Learning (PBL)

Integrante	RM	Turma
Miriã Leal Mantovani	RM567811	2TIAOR-2026
João Pedro Santos Azevedo	RM566701	2TIAOR-2026

Tutor: Leonardo Ruiz Orabona

Repositório GitHub: <https://github.com/joaostazevedo172/cardioia-fase1.git>

Agosto de 2026

1. Visão geral da entrega

Esta fase tem um objetivo aparentemente modesto e, na prática, decisivo: montar a base de dados sobre a qual todos os módulos inteligentes do CardioliA serão construídos nas Fases 2 a 7. Encontrar, limpar e preparar dados é a etapa mais demorada de qualquer projeto de Inteligência Artificial — e a que mais determina o teto de qualidade do resultado final.

Foram entregues três conjuntos de dados, todos superando os mínimos exigidos:

Parte	Conteúdo entregue	Entregue	Mínimo
1 — Numéricos (IoT/ML)	Coorte sintética de pacientes cardiológicos (CSV + XLSX)	800 linhas × 33 colunas	100 linhas
2 — Textuais (NLP)	Dois clássicos de domínio público + dois corpora autorais em português	4 arquivos .txt (~83 mil palavras)	2 arquivos
3 — Visuais (VC)	Eletrocardiogramas rotulados em 6 classes diagnósticas	120 imagens .png	100 imagens

1.1 A decisão metodológica central

Havia dois caminhos possíveis. O primeiro, mais rápido, seria baixar um dataset público conhecido — o UCI Heart Disease, por exemplo —, recolher dois PDFs avulsos e um pacote de radiografias do Kaggle. O resultado seria uma entrega válida, porém com dois problemas estruturais: as três bases ficariam completamente desconectadas entre si, e a base numérica seria idêntica à de milhares de outros projetos.

Optamos pelo segundo caminho: construir um ecossistema de dados coerente e autoral, inteiramente gerado por código versionado. Cada base possui um script gerador próprio, com semente aleatória fixa (20260806), o que garante quatro propriedades que uma base baixada não oferece.

- Reprodutibilidade: qualquer pessoa que execute os scripts obtém exatamente os mesmos arquivos, bit a bit.
- Rastreabilidade: conhecemos o processo gerador dos dados, o que permitirá verificar, nas fases seguintes, se o modelo aprendeu a relação clínica correta ou apenas um atalho estatístico.
- Conformidade com a LGPD: dado de saúde é dado pessoal sensível (Art. 5º, II e Art. 11). Dado sintético elimina o problema na origem, pois não existe titular a ser protegido.
- Unicidade: nenhum outro grupo terá esta base.

1.2 O diferencial: as três modalidades descrevem os mesmos pacientes

O campo `id_paciente` (formato CARD-0001) funciona como chave de junção multimodal. O prontuário do paciente CARD-0634 descreve exatamente a linha CARD-0634 da planilha; o laudo de ECG registrado na tabela corresponde à classe da imagem. Não são três bases sobre cardiologia — são três olhares sobre a mesma coorte.

Essa escolha viabiliza, nas fases seguintes, três coisas que uma base desconectada simplesmente não permite:

- Validar a extração de entidades por NLP contra o gabarito tabular — algo raríssimo, pois normalmente exigiria anotação manual de todo o corpus.
- Comparar, no mesmo paciente, o desempenho de um modelo tabular e de um modelo de linguagem.
- Construir fusão multimodal (late fusion) de tabela, texto e imagem na Fase 7.

2. Parte 1 — Dados Numéricos

Arquivos: data/cardioia_pacientes.csv e data/cardioia_pacientes.xlsx | **Gerador:** src/01_gerar_dataset_numerico.py

2.1 Origem dos dados

Os dados são simulados. A "Coorte Sintética Hospital Cardiola" reúne 800 pacientes fictícios. Não se trata, porém, de amostragem aleatória independente: cada variável foi gerada condicionada às anteriores, seguindo relações de dependência descritas na literatura cardiológica (estudo de Framingham, diretrizes da Sociedade Brasileira de Cardiologia e da American Heart Association).

A pressão sistólica, por exemplo, cresce com a idade, com o IMC e com o diagnóstico prévio de hipertensão; o HDL é menor em homens, fumantes e sedentários. O desfecho clínico vem de um modelo logístico explícito que combina idade, sexo, tabagismo, diabetes, hipertensão, história familiar, pressão, LDL, HDL, IMC e nível de atividade física — o "ground truth" do processo gerador, que ficará disponível para auditar o aprendizado do modelo na Fase 2.

2.2 Perfil da base

Indicador	Valor
Pacientes	800
Variáveis	33
Prevalência de evento cardiovascular em 12 meses	aproximadamente 18%
Estratificação de risco	Baixo 29% · Intermediário 36% · Alto 35%
Distribuição por sexo	58% masculino / 42% feminino (viés deliberado)
Células ausentes	aproximadamente 200, com padrão não aleatório proposital

2.3 Variáveis mais relevantes do ponto de vista clínico

Das 33 colunas, seis merecem destaque — e a justificativa de cada uma vale mais que a lista em si.

Variável	Por que importa para um projeto de IA em saúde
idade	É o preditor isolado mais forte de risco cardiovascular: o risco praticamente dobra a cada década. É também a variável que mais facilmente se transforma em atalho para o modelo — se ele acertar apenas pela idade, não aprendeu cardiologia alguma.
dor_toracica_tipo	Uma anamnese bem conduzida ainda supera diversos exames em valor preditivo. É a ponte natural entre o módulo tabular e o de NLP, pois a mesma informação aparece em texto livre nos prontuários.

Variável	Por que importa para um projeto de IA em saúde
colesterol_ldl e colesterol_hdl	O LDL é o alvo causal da aterosclerose; o HDL entra com sinal invertido, por ser protetor. Se o modelo aprender que "HDL alto significa risco alto", há erro de sinal ou vazamento de dados — é um excelente teste de sanidade.
pressao_sistolica	Fator de risco modificável com relação dose-resposta contínua e sem limiar de segurança. É também a leitura que virá do wearable ESP32 na Fase 3, o que a torna a ponte com o módulo de IoT.
diabetes	As diretrizes o tratam como equivalente de risco coronariano. Interage fortemente com IMC e glicemia, sendo um bom caso para testar se o modelo captura interações ou apenas efeitos aditivos.
ecg_repouso	É o único campo tabular conectado diretamente à base de imagens, viabilizando a fusão multimodal prevista para a Fase 7.

Sobre o alvo do modelo

A variável evento_cardiaco_12m tem prevalência de aproximadamente 18%. Isso obriga o uso de recall, F1 e AUC-PR nas fases seguintes: a acurácia é enganosa nesse cenário, pois um modelo que simplesmente preveja "nenhum paciente terá evento" já acertaria 82% dos casos — sem ter aprendido absolutamente nada.

3. Parte 2 — Dados Textuais

Arquivos: pasta docs/ — quatro arquivos .txt, aproximadamente 83 mil palavras

3.1 Composição do corpus

Arquivo	Origem	Natureza	Palavras
texto_01_harvey_1628_de_motu_cordis.txt	Project Gutenberg #67065 (domínio público)	Tratado fundador da cardiologia (Harvey, 1628)	~20.000
texto_02_huxley_1878_descoberta_da_circulacao.txt	Project Gutenberg #2939 (domínio público)	Texto expositivo de divulgação (Huxley, 1878)	~8.000
texto_03_prontuarios_sinteticos_cardioia.txt	Autoral (src/03)	300 prontuários em português, alinhados ao CSV	~45.000
texto_04_teleatendimento_dialogos_cardioia.txt	Autoral (src/03)	200 diálogos paciente-assistente, rotulados	~10.000

Os dois primeiros arquivos são obtidos pelo script `src/04_baixar_textos_publicos.py`, que remove automaticamente o cabeçalho e o rodapé de licença do Project Gutenberg — sem essa limpeza, o modelo de NLP aprenderia o ruído jurídico repetido em vez do conteúdo médico. Os dois últimos são gerados a partir da própria coorte numérica, preservando o alinhamento por `id_paciente`.

Cada diálogo do corpus de teleatendimento já vem rotulado em três dimensões — intenção, urgência e sentimento —, disponíveis também em formato tabular no arquivo `data/corpus_teleatendimento.csv`.

3.2 Como esses textos podem ser explorados por algoritmos de NLP

a) Extração de entidades clínicas (NER) com gabarito. Aplicar reconhecimento de entidades nomeadas sobre os prontuários para extrair sintomas, medicações e valores de exame. O diferencial é que a resposta correta está na planilha: podemos calcular precisão e recall reais da extração, algo incomum em corpus público, onde normalmente seria necessário anotar tudo manualmente.

b) Classificação de intenção e triagem por urgência. Os 200 diálogos rotulados treinam o classificador que decide se uma mensagem é emergência — orientando o acionamento do SAMU — ou dúvida administrativa. É o núcleo do assistente virtual da Fase 5. Em saúde o erro não é simétrico: classificar uma emergência como rotina pode custar uma vida, de modo que o modelo deve ser otimizado para recall na classe crítica, aceitando falsos positivos.

c) Análise de sentimento aplicada à adesão ao tratamento. Os rótulos de sentimento permitem identificar pacientes em sofrimento emocional, que abandonam o tratamento com mais frequência. Um assistente que responde apenas tecnicamente a "estou com medo do cateterismo" perde o paciente.

d) Classificação de tópicos e mapeamento de barreiras de acesso. Agrupar as mensagens revela padrões acionáveis: a categoria de acesso ao tratamento concentra relatos sobre custo de medicação e distância até o serviço — informação de gestão, não apenas clínica.

e) Contraste diacrônico da linguagem médica. Comparar o vocabulário do século XVII com o prontuário contemporâneo é um laboratório de domain shift: um modelo treinado em texto moderno degrada em texto histórico, e vice-versa. É a forma mais didática de demonstrar por que um modelo treinado no hospital A pode falhar no hospital B.

Por que isso é relevante para IA em saúde

Estima-se que a maior parte da informação clínica registrada esteja em texto livre, não em campos estruturados. Um projeto que consome apenas tabelas ignora a maior parte do que o médico efetivamente escreveu. Além disso, o corpus textual é a única modalidade que carrega a voz do paciente — o que ele sente, teme e não consegue pagar. Sem isso, o sistema otimiza o diagnóstico e falha na adesão, que é justamente onde o tratamento cardiovascular costuma naufragar.

4. Parte 3 — Dados Visuais

Arquivos: assets/ecg/ — 120 imagens .png | **Manifesto rotulado:** data/ecg_labels.csv | **Gerador:** src/02_gerar_imagens_ecg.py

4.1 Origem e método de síntese

As imagens são simuladas. Cada traçado é sintetizado como soma de componentes gaussianas que representam as ondas P, Q, R, S e T — abordagem inspirada no gerador ECGSYN (McSharry et al., 2003), aqui reimplementada de forma simplificada e autoral. O sinal é renderizado sobre papel milimetrado no padrão clínico de 25 mm/s e 10 mm/mV, com grade fina de 0,04 s e grade grossa de 0,2 s.

Classe	Imagens	Achado simulado	FC média
normal	20	Ritmo sinusal regular	~75 bpm
taquicardia_sinusal	20	Frequência acima de 100 bpm	~132 bpm
bradicardia_sinusal	20	Frequência abaixo de 55 bpm	~46 bpm
fibrilacao_atrial	20	Ausência de onda P e intervalo RR irregular	~106 bpm
isquemia_infra_st	20	Infradesnivelamento do segmento ST	~75 bpm
iam_supra_st	20	Supradesnivelamento de ST com onda T apiculada	~90 bpm

Foram injetados de propósito quatro ruídos realistas: deriva de linha de base decorrente da respiração (0,15 a 0,4 Hz), interferência da rede elétrica em 60 Hz, ruído eletromiográfico de alta frequência e variabilidade de amplitude entre pacientes. Sem eles, a rede neural aprenderia um traçado limpo demais e desabaria diante de qualquer exame real.

4.2 Como essas imagens podem ser analisadas por Visão Computacional

a) Classificação por rede neural convolucional. A base é balanceada (20 imagens por classe) e integralmente rotulada, pronta para transfer learning com arquiteturas como ResNet ou EfficientNet. O balanceamento é intencional e contrasta de propósito com o desbalanceamento da base tabular — as duas situações exigem estratégias diferentes de treino e de avaliação.

b) Detecção de bordas e segmentação do complexo QRS. Filtros de Sobel ou Canny isolam o pico R; a partir dele calculam-se os intervalos RR, a frequência cardíaca e a variabilidade da frequência (HRV). O manifesto data/ecg_labels.csv já traz a frequência estimada por detecção de picos com período refratário de 200 ms, servindo de gabarito para validar a implementação do grupo.

c) Reconhecimento de anomalias no segmento ST. As classes de isquemia e de infarto diferem por um deslocamento sutil, de poucos pixels, em uma região específica do traçado. É o caso ideal para mapas de atenção (Grad-CAM): se a rede destacar o segmento ST, aprendeu o achado clínico; se destacar a grade do papel ou a borda da imagem, aprendeu um artefato — e o modelo é inútil apesar de uma métrica aparentemente boa.

d) Detecção de anomalias sem rótulo. Treinar um autoencoder apenas com a classe normal e usar o erro de reconstrução como escore de anormalidade. Essa abordagem espelha o cenário hospitalar real, em que exames normais são abundantes e os patológicos, raros.

e) Teste de robustez a artefatos. Como controlamos a geração do ruído, podemos variar sua intensidade e medir a queda de desempenho — um teste de estresse que uma base baixada pronta não permite realizar.

Por que isso é relevante para IA em saúde

O eletrocardiograma é o exame cardiológico mais barato, rápido e disponível do mundo, e sua interpretação depende de treinamento especializado que falta em boa parte da rede básica. Um classificador confiável de ECG é, na prática, triagem em escala: identifica quem precisa de cardiologista agora e quem pode aguardar. Combinado ao wearable da Fase 3, deixa de ser um exame pontual e passa a ser monitoramento contínuo. Há ainda a lição que sustenta todo o restante: em imagem médica o modelo aprende com enorme facilidade o atalho errado — o formato do papel, o texto do cabeçalho, o equipamento utilizado. Sem interpretabilidade, não há uso clínico responsável.

5. Governança de Dados e Viés

O documento completo encontra-se em docs/GOVERNANCA_DE_DADOS.md. Sintetizamos aqui os pontos centrais.

5.1 Enquadramento legal

Dados de saúde são dados pessoais sensíveis segundo a LGPD (Lei 13.709/2018, Art. 5º, II, e Art. 11). Seu tratamento exige consentimento específico ou uma das hipóteses legais restritas — condição que um projeto acadêmico dificilmente satisfaz para dados identificáveis. A síntese de dados não é um atalho: é uma técnica reconhecida de compartilhamento com preservação de privacidade.

5.2 Vieses deliberadamente mantidos na base

Um erro comum é gerar dados perfeitamente balanceados. Isso ensina o modelo — e o grupo — a ignorar o problema mais importante da IA em saúde. Optamos por injetar vieses reais e documentá-los, para que sejam medidos, e não escondidos.

Viés	Como está codificado	Métrica a monitorar
Sexo (58% homens)	Coortes cardiológicas históricas sub-representam mulheres. Além disso, mulheres recebem com mais frequência o rótulo de dor atípica, reproduzindo o fato clínico de que a apresentação feminina do infarto foge do padrão.	Recall (sensibilidade) por sexo nas Fases 2 e 6. Se o recall feminino for materialmente menor, o modelo reproduz o viés e não pode ir a produção.
Acesso geográfico	O tempo até o primeiro atendimento é sistematicamente maior no Interior e na Zona Rural (medianas de ~68 e ~105 minutos contra ~26 na Capital).	Tratar a variável como auditoria de equidade, nunca como feature de diagnóstico — sob risco de o modelo desqualificar pacientes rurais em vez de priorizá-los.
Ausência não aleatória (MAR)	Exames laboratoriais faltam em ~11% dos pacientes do Interior e da Zona Rural, contra ~3% na Capital. A ausência carrega informação sobre desigualdade de acesso.	Manter um indicador binário de ausência junto a qualquer imputação. Imputar pela média apaga a informação e reforça a desigualdade.
Desbalanceamento de classe	O desfecho tem prevalência de ~18%.	Recall, F1, AUC-PR e matriz de confusão. Nunca acurácia isolada.

5.3 Limitações declaradas

- A base não substitui dado real. As correlações foram parametrizadas por nós; um desempenho excelente aqui não possui validade clínica alguma.
- Não há efeitos temporais — progressão de doença, sazonalidade, adesão ao longo do tempo. A Fase 6 exigirá enriquecimento temporal da base.
- Não há comorbidades raras nem interações medicamentosas.

- Os ECGs sintéticos têm morfologia simplificada e derivação única; servem para exercitar o pipeline de visão computacional, não para validação clínica.
- O corpus textual é gerado por template e tem, portanto, menos variabilidade linguística que o texto humano real — abreviações, erros de digitação e jargão idiossincrático estão sub-representados.

6. Organização do repositório e reprodução

Caminho	Conteúdo
README.md	Documentação principal, com os links públicos dos dados
data/	CSV e XLSX da coorte, dicionário de dados, manifesto dos ECGs e corpus de teleatendimento em formato tabular
docs/	Os quatro arquivos .txt do corpus e o documento de governança de dados
assets/ecg/	As 120 imagens, organizadas em seis subpastas por classe diagnóstica
src/	Os quatro scripts geradores em Python
notebooks/	Notebook de exploração dos dados e auditoria de viés

Para reproduzir integralmente a entrega, basta clonar o repositório, instalar as dependências listadas em requirements.txt e executar os quatro scripts da pasta src na ordem numérica. O notebook notebooks/01_exploracao_dados.ipynb encerra com um checklist automático que confere as contagens mínimas exigidas pela rubrica.

As pastas já estão preparadas para as fases seguintes: os notebooks do Colab ou do Jupyter das Fases 2 a 7 consomem diretamente data/ e assets/.

6.1 Ponte para as próximas fases

Fase	O que já está pronto nesta entrega
2 — Diagnóstico automatizado	Alvos de classificação binária e multiclasse, além do processo gerador para auditar o que o modelo efetivamente aprendeu
3 — Monitoramento contínuo (IoT)	Pressão sistólica, frequência cardíaca de repouso e saturação de oxigênio são exatamente as leituras do wearable com ESP32
4 — Visão computacional	120 ECGs rotulados e manifesto com frequência cardíaca de referência
5 — Assistente virtual	200 diálogos com intenção, urgência e sentimento já rotulados
6 — Previsão de crises	Base preparada para enriquecimento temporal
7 — Plataforma integrada	O campo id_paciente já unifica tabela, texto e imagem para fusão multimodal

7. Referências

- HARVEY, W. An Anatomical Disquisition on the Motion of the Heart and Blood in Animals, 1628. Project Gutenberg, ebook nº 67065.
- HUXLEY, T. H. William Harvey and the Discovery of the Circulation of the Blood, 1878. Project Gutenberg, ebook nº 2939.
- McSHARRY, P. E. et al. A dynamical model for generating synthetic electrocardiogram signals. IEEE Transactions on Biomedical Engineering, 2003.
- SOCIEDADE BRASILEIRA DE CARDIOLOGIA. Diretrizes de Prevenção Cardiovascular.
- BRASIL. Lei nº 13.709/2018 — Lei Geral de Proteção de Dados Pessoais, Art. 5º, II, e Art. 11.

Aviso

Nenhum arquivo deste projeto contém dado de pessoa real. Nenhum conteúdo aqui constitui orientação médica. As bases destinam-se exclusivamente ao desenvolvimento acadêmico do projeto CardiolA.